

实验三：单细胞基因表达最小二乘拟合及细胞分化轨迹解析


一、实验目的

1. 掌握单细胞表达矩阵的预处理方法（高可变基因筛选、标准化），理解基因维度优化的核心思路，能选择合适的维度优化方案（基因聚类/并行分块）处理高维基因数据。
2. 熟练运用最小二乘多项式拟合方法，结合细胞标签时序，实现基因表达曲线的拟合，掌握拟合优度与误差分析的计算方法，明确正则化对拟合效果的影响。
3. 学会基于细胞标签进行时间点分配，明确同一阶段内细胞的排序逻辑，避免时间点分配不合理导致的拟合失真。
4. 了解基于基因拟合趋势的细胞分化轨迹排序方法，初步理解细胞单分支/双分支分化机制，实现数学方法与单细胞生信问题的结合。
5. 掌握实验数据的验证方法，能通过假设检验、相关性分析等手段验证实验结果的合理性，提升实验的严谨性。

二、实验原理

2.1 单细胞基础背景补充

单细胞 RNA-seq 技术可捕捉单个细胞的基因表达特征，打破传统 bulk RNA-seq 对细胞群体的平均化分析，能清晰呈现细胞间的异质性（即同一细胞类型/阶段的细胞，基因表达存在细微差异）。细胞分化是指细胞从原始未分化状态逐渐特化，形成不同功能细胞类型的过程，该过程中基因表达会呈现连续的动态变化，而细胞标签（如细胞表面标志物、发育阶段标识）可直接对应细胞的分化状态，为时序分析提供基础。




2.2 双分支分化过程具体介绍

细胞分化并非均为单一线性路径，双分支分化是常见的分化模式，即起始细胞群体在分化过程中，受不同分子信号调控，逐渐分化为两种不同功能的细胞谱系。以下列举2种具体且易理解的双分支分化过程，帮助理解实验中双分支轨迹的解析逻辑：

1. 造血干细胞（HSC）双分支分化：造血干细胞是骨髓中具有自我更新和多向分化

潜能的原始细胞，其经典双分支分化路径为：起始态（HSC，造血干细胞）→ 共同前体细胞（MPP，多能造血祖细胞）→ 分支1（髓系谱系：GMP→单核细胞/粒细胞，负责机体免疫防御、炎症反应）；分支2（淋巴系谱系：CLP→T细胞/B细胞，负责特异性免疫应答）。其中，HSC和MPP为两个分支的共同起始/过渡阶段，GMP、CLP分别为两个分支的特异前体细胞，基因表达在分支点（MPP阶段）会出现明显的谱系特异性差异。

2. 神经干细胞（NSC）双分支分化：神经干细胞存在于胚胎和成年脑组织中，可分化为神经细胞和神经胶质细胞，双分支路径为：起始态（NSC，神经干细胞）→ 过渡态（神经前体细胞NPC）→ 分支1（神经元，负责神经信号传递、信息处理）；分支2（神经胶质细胞，分为星形胶质细胞和少突胶质细胞，负责支持、保护神经元）。其中，神经元特异基因（如MAP2）仅在分支1中显著上调，胶质细胞特异基因（如GFAP）仅在分支2中显著上调，可通过基因表达趋势差异区分两个分支。本实验中，双（多）分支轨迹解析的核心的是通过基因拟合趋势，捕捉分支特异基因的表达差异，进而反向验证双分支分化路径，无需依赖复杂的伪时间算法。



2.3 单细胞数据预处理

单细胞 RNA-seq 表达矩阵存在测序深度差异、基因表达异质性问题，需先进行高可变基因（HVG）筛选与标准化处理。HVG 筛选可保留表达变异较大、能反映细胞异质性的基因，剔除低表达、无差异的冗余基因，减少后续计算量。标准化处理采用 Seurat 标准方法，消除细胞测序深度差异，使不同细胞的基因表达量具有可比性，标准化公式如下：

$$X_{ij}^{\text{norm}} = \log_2 \left(\frac{X_{ij}}{\sum_{i=1}^n X_{ij}} \times 10^4 + 1 \right)$$

其中， X_{ij} 为基因 i 在细胞 j 中的原始表达量， X_{ij}^{norm} 为标准化后表达量， n 为基因总数，该公式可有效校正测序深度差异，同时通过对数转换降低极端值影响。

2.4 基因维度优化

筛选后的 HVG 仍有 2000-3000 维，需通过维度优化减少冗余。方案1（基因聚类）采用 K-means 聚类算法，将表达模式相似的基因聚为模块，以模块中心向量替代单个基因进行拟合，提升计算效率并赋予拟合结果生物学意义。K-means 聚类的核心准则是最小化各模块内基因表达的平方和误差（SSE），公式如下：

$$SSE = \sum_{c=1}^k \sum_{g_i \in C_c} \|x_{g_i} - \mu_c\|^2$$

其中， C_c 为第 c 个基因模块， x_{g_i} 为基因 g_i 的标准化表达向量（ $1 \times m$ ， m 为细胞数）， μ_c 为第 c 个模块的中心向量（模块内所有基因表达的均值）， $\|\cdot\|$ 为欧氏距离， k 为模块数（8-15，可通过轮廓系数确定最优值）。

方案2（并行分块）无需聚类，将高维基因随机分块（每500个基因一组），利用拟合过程互不影响的特点，并行进行最小二乘拟合，适合追求计算速度的场景。

2.5 时间点分配策略

为满足最小二乘拟合对时间点的样本量约束，需要为抽样细胞分配连续的时间点。本实验完全放弃全局伪时间及降维相关方法，仅基于已知细胞阶段标签的生物学先验知识和基因模块表达数据，采用“全局时间轴+阶段内局部排序”的策略，具体如下：

- 全局时间轴构建：直接使用已知细胞阶段标签的固有顺序（例如 HSC→MPP→GMP→单核细胞等），每个阶段对应一个连续的时间区间。区间长度可采用两种设定方式，二选一即可：① 固定间隔设定，阶段间间隔 $\Delta T_{stage} = 1$ （人为设定，简化计算）；② 动态间隔设定，区间长度正比于该阶段的细胞总数，细胞数量越多，时间区间越长，更贴合细胞发育的实际进程。该全局时间轴的构建不依赖任何数据降维方法，完全基于实验数据提供的生物学先验知识，避免引入人为偏差。
- 阶段内排序驱动模块筛选：对标准化后的高可变基因进行 K-means 聚类，得到基因模块及模块中心向量。对于每两个相邻的生物学阶段（如阶段 i 和阶段 $i+1$ ），计算每个基因模块在阶段 i 与阶段 $i+1$ 之间的平均表达差异（或通过 t 检验计算差异统计量），选择差异最显著的1个模块（或前3个差异模块的平均表达）作为该阶段内部的“排序驱动模块”。该模块的表达变化直接驱动细胞从当前阶段向下一阶段分化，其表达量在当前阶段内会呈现连续渐变趋势，是阶段内细胞排序的核心依据。
- 阶段内细胞排序：在每个阶段内部，不使用任何全局降维方法（如 PCA），仅基于步骤2筛选出的排序驱动模块，计算每个细胞在该模块上的中心表达值（即细胞在该模块所有基因上的平均表达量）。根据模块表达与分化的相关性，按该中心表达值从低到高或从高到低对细胞进行排序。该排序仅用于阶段内部的时间点均匀插值，不用于跨阶段的细胞顺序比较，避免混淆不同阶段的发育时序。
- 时间点分配原则：时间点仅在每个阶段内部进行分配，阶段间的整体时序由已知的生物学阶段顺序自然保证，无需人工强制衔接。

该方法的时间点完全来源于基因表达数据的结构（通过阶段间差异模块识别），且不依赖于任何全局降维或伪时间算法，避免了循环论证，同时贴合“从基因表达模式出发构建轨迹排序”的核心需求。

2.6 最小二乘曲线拟合原理

最小二乘拟合的核心是寻找最优多项式参数，使拟合值与实际基因表达值的残差平方和最小。设基因表达量 y 与时间 t 的拟合多项式为 $\hat{y}(t) = a_0 + a_1 t + a_2 t^2 + \dots + a_p t^p$ ，其中 $a_0, a_1, \dots, a_p$ 为拟合参数，拟合准则为最小化残差平方和（RSS）：

$$RSS = \sum_{j=1}^{n_s} (y_j - \hat{y}_j)^2$$

其中， y_j 为实际基因表达量， $\hat{y}_j$ 为拟合值， n_s 为抽样细胞数。通过求解正规方程组可得到最优参数，拟合效果通过拟合优度（ R^2 ）、均方根误差（RMSE）评价，公式如下：

$$R^2 = 1 - \frac{\sum_{j=1}^{n_s} (y_j - \hat{y}_j)^2}{\sum_{j=1}^{n_s} (y_j - \bar{y})^2}$$

$$RMSE = \sqrt{\frac{1}{n_s} \sum_{j=1}^{n_s} (y_j - \hat{y}_j)^2}$$

其中， $\bar{y}$ 为基因表达量均值， R^2 越接近1、RMSE 越小，拟合效果越好。

正则化最小二乘（Lasso）是在普通最小二乘基础上增加正则化项，用于解决过拟合问题，正则化公式为：

$$\min_a \sum_{j=1}^{n_s} (y_j - \sum_{p=0}^{p_{max}} a_p t_j^p)^2 + \lambda \sum_{p=0}^{p_{max}} a_p^2$$

其中， λ 为正则化参数， λ 越大，正则化强度越强，可有效抑制模型过度拟合噪声； $\lambda=0$ 时，正则化最小二乘退化为普通最小二乘。

其他机器学习类拟合方法：可选用随机森林回归、支持向量回归（SVR）等方法进行基因表达曲线拟合，此类方法无需假设基因表达与时间的多项式关系，能更好捕捉复杂非线性趋势，但计算复杂度高于最小二乘拟合，适合有一定机器学习基础的学生尝试。

2.7 细胞轨迹排序原理

采用**基于显著趋势基因的投票排序**，并可在选做部分实现**从抽样细胞向全体细胞的伪时间扩展**。**核心排序方法**（避免循环验证）：

提取所有显著趋势基因（ $R^2>0.5, p<0.05$ ）的拟合曲线，对每个基因，计算其在所有细胞上的拟合值 $\hat{y}_g(t_j)$ 。对于每对细胞 (j_1, j_2) ，若基因 g 的拟合值满足 $\hat{y}_g(t_{j_1}) < \hat{y}_g(t_{j_2})$ ，则认为该基因“投票”给 j_1 应排在 j_2 之前。统计所有基因的投票结果，采用**排序聚合算法**（如 Kemeny 最优排序或基于拓扑排序的启发式方法）得到最终细胞顺序。该方法不依赖 PCA，避免循环论证，且生物学解释性强：基因表达升高/降低的趋势直接决定细胞相对顺序。

从抽样细胞到全体细胞的伪时间扩展。在拟合步骤中，我们仅在抽样细胞上构建了拟合曲线。若需要对全体细胞排序，可采用以下策略：

策略 A（插值法）：对全体细胞，利用已拟合的基因曲线，根据该细胞在显著趋势基因上的实际表达向量，通过最近邻或高斯过程回归预测其伪时间。具体：对全体细胞中的每个细胞 j ，计算其与所有抽样细胞在显著趋势基因表达上的欧氏距离，取距离最近的 k 个抽样细胞（如 $k=5$ ），其伪时间的加权平均（权重为距离倒数）作为该细胞的伪时间。

策略 B（模型预测）：将抽样细胞的伪时间作为训练目标，全体细胞的显著趋势基因

表达作为特征，训练一个随机森林回归模型，预测全体细胞的伪时间。
该扩展允许在不重新拟合所有细胞的情况下，将轨迹顺序推广到完整数据集。

2.8 假设检验与验证原理

2.8.1 基因表达趋势显著性检验

采用 Pearson 相关性检验验证基因表达与时间的关联，原假设 H_0 ：基因表达与时间无关（相关系数 $r=0$ ），备择假设 H_1 ：基因表达与时间显著相关（ $r \neq 0$ ）， $p < 0.05$ 则拒绝 H_0 ，认为基因具有显著表达趋势。

时间点充足性通过残差方差检验验证，公式为：

$$\sigma^2 = \frac{1}{n_s - p - 1} \sum_{j=1}^{n_s} (y_j - \hat{y}_j)^2$$

其中， σ^2 为残差方差， $\sigma^2 < 0.05$ 说明时间点充足、拟合精度达标。轨迹排序合理性通过 Spearman 相关系数 ρ 验证， $\rho > 0.7$ （ $p < 0.05$ ）说明排序与已知标签时序一致。

2.8.2 正则化参数 λ 的交叉验证选择

对于 Lasso 正则化最小二乘，最优 λ 通过 5 折交叉验证确定：将抽样细胞随机分为 5 份，每份依次作为验证集，其余 4 份作为训练集，对一系列候选 λ （如 0.001, 0.01, 0.1, 0.5, 1, 2, 5, 10）计算验证集上的均方根误差（RMSE），选择平均 RMSE 最小的 λ 。可绘制 λ -CV 误差曲线辅助判断。

2.8.3 轨迹排序合理性验证：NMI 与 ARI

原报告中 Spearman 相关系数依赖已知标签的时序（连续），但实际标签通常为离散阶段（如 HSC, MPP, GMP）。NMI（归一化互信息）和 ARI（调整兰德指数）更适合评估离散阶段与排序后分组的吻合程度。

验证流程：

- 将排序得到的细胞顺序按阶段细胞数量比例划分为若干区间（例如，已知有 4 个阶段，每个阶段细胞数分别为 n_1, n_2, n_3, n_4 ，则按排序顺序取前 n_1 个细胞赋予阶段标签 1，接下来 n_2 个赋予标签 2，依此类推）。
- 计算该预测阶段划分与真实标签之间的 NMI 和 ARI。NMI 取值范围 [0,1]，值越大表示划分与真实阶段一致性越高。ARI 取值范围 [-1,1]，接近 1 表示完全一致，0 表示随机划分。
- 若 $NMI > 0.6$ 且 $ARI > 0.5$ ，认为排序合理。

2.8.4 负对照实验：随机打乱时间点对拟合的影响

目的：验证所分配的时间点是否真正携带了基因表达的时序信息，避免过度解释噪声。

方法：在完成原始时间点分配与拟合后，将时间点向量 t 随机打乱（即打破时间点与细胞之间的对应关系），然后重新对同一组细胞进行最小二乘拟合（相同的多项式阶数和正则化参数），计算打乱后的平均 R^2 和平均 RMSE。重复随机打乱 100 次，得到 R^2_{shuffle} 的分布。若原始 R^2 显著高于 R^2_{shuffle} 的 95% 分位数（即 $p < 0.05$ ），则说明原始时间点确实反映了真实的表达变化规律，轨迹可信。若原始 R^2 落在随机打乱的分布之内，则表明观察到的拟合优度可能是由于过拟合或数据噪声造成的假象，轨迹不可靠。该负对照实验是识别“伪轨迹”的有效手段，推荐纳入常规分析流程。

三、实验内容与步骤

3.1 实验材料与工具

- 实验数据：单细胞 RNA-seq 表达矩阵（基因×细胞）、已知细胞标签（分化阶段/类型，如 HSC→MPP→GMP→单核细胞），可选用小鼠骨髓造血分化数据集。
- 实验工具：Python（numpy、pandas、scikit-learn、scanpy）或 Matlab，用于数据预处理、聚类、拟合与排序；R（Seurat），用于高可变基因筛选与标准化。

3.2 具体实验步骤

步骤 1：数据预处理

- 高可变基因筛选：采用 Seurat 软件，保留表达变异系数前 20%-30% 的基因，得到高可变基因集合 $G = \{g_1, g_2, \dots, g_n\}$ ($n=2000-3000$)。
- 表达矩阵标准化：对筛选后的基因表达矩阵进行标准化，消除细胞测序深度差异，得到标准化矩阵 X^{norm} 。请注意，Dataset 文件中给定预处理好的单细胞数据和标签。

步骤 2：基因维度优化（二选一）

方案 1：基因聚类→模块拟合（推荐）

- K-means 聚类：对标准化后的 HVG 进行 K-means 聚类，通过轮廓系数确定最优模块数 k (8-15)，轮廓系数公式为：

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

其中， $a(i)$ 为细胞 i 与同模块内其他细胞的平均距离， $b(i)$ 为细胞 i 与最近异模块细胞的平均距离， $s(i)$ 越接近 1，聚类效果越好。

- 模块中心计算：计算每个基因模块的中心向量 μ_c （模块内所有基因表达量的均值），作为该模块的典型表达轮廓。

方案 2：并行分块处理

- 基因分块：将标准化后的 HVG 随机分为 4-6 组，每组 500 个基因，确保分组随机无偏差。
- 并行拟合准备：对每组基因单独进行后续最小二乘拟合，拟合完成后汇总所有基因的趋势结果。

步骤 3：时间点分配

3.1 全局时间轴设定

直接使用已知细胞阶段标签的固有顺序（如阶段 1→阶段 2→阶段 3→...），为每个阶段分配连续时间区间，二选一即可：

- 固定间隔设定：阶段间间隔 $\Delta T_{stage} = 1$ ，例如阶段 1 对应时间区间 $[0, 1]$ ，阶段 2 对应 $[1, 2]$ ，以此类推，简化计算。
- 动态间隔设定：区间长度正比于该阶段细胞总数 M_i ，计算公式为 $\Delta T_i = \frac{M_i}{\sum M_i} \times T_{total}$ ，其中 T_{total} 为预设总时间（如 10），使细胞数量多的阶段获得更长的时间区间，贴合实际发育进程。

3.2 阶段内排序驱动模块筛选

- 对标准化后的 HVG 进行 K-means 聚类 ($k=8\sim 15$)，得到基因模块及各模块中心向

量 μ_c 。

2. 针对每两个相邻阶段（如阶段 i 和阶段 $i+1$ ），计算每个基因模块在两个阶段内的平均表达量，通过计算表达量差值（或 t 检验），筛选出差异最显著的 1 个模块（或前 3 个差异模块），作为阶段 i 的排序驱动模块。
3. 记录每个阶段对应的排序驱动模块，明确模块表达与分化的相关性（即模块表达量随分化进程升高或降低），确定后续排序方向。

3.3 阶段内细胞排序与抽样

对每个阶段 i ，计算该阶段内每个细胞在其排序驱动模块上的中心表达值（细胞在该模块所有基因上的平均表达量）。根据排序驱动模块与分化的相关性，按中心表达值从低到高或从高到低，对该阶段内的细胞进行排序（仅阶段内排序，不跨阶段比较）。确定抽样量：根据最小二乘拟合的多项式阶数 p 和该阶段细胞总数 M_i ，按公式 $n_s \geq \max(3p + 1, 0.05M_i)$ 确定抽样量 n_s ，其中 $3p + 1$ 满足参数估计需求， $0.05M_i$ 确保抽样具有代表性。均匀抽样：从排序后的细胞中，按排序位置均匀抽取 n_s 个细胞（如排序位置 1、 $\lfloor M_i/(n_s - 1) \rfloor$ 、 $2\lfloor M_i/(n_s - 1) \rfloor \dots$ ），确保抽样细胞覆盖模块表达的完整范围。

3.4 阶段内时间点插值分配

确定阶段时间区间：根据步骤 3.1 设定的全局时间轴，明确每个阶段 i 的起始时间 T_i^{start} 和结束时间 T_i^{end} （ $T_i^{end} = T_i^{start} + \Delta T_i$ ）。

均匀插值分配时间点：对每个阶段内抽样的 n_s 个细胞，按排序顺序采用均匀插值公式分配连续时间点，公式如下：

$$t_{ij} = T_i^{start} + \frac{j-1}{n_s-1} \times (T_i^{end} - T_i^{start}), j = 1, 2, \dots, n_s$$

其中， t_{ij} 为第 i 个阶段第 j 个排序后抽样细胞的时间点， j 为细胞排序序号（对应阶段内发育进度），确保阶段内时间点连续均匀，满足最小二乘拟合需求。

3.5 时间点分配合理性检验

1. 阶段内排序单调性检验：计算每个阶段内细胞排序位置与排序驱动模块中心表达值的 Spearman 相关系数，若 $\rho > 0.8$ （ $p < 0.05$ ），说明排序合理；否则更换差异更显著的模块作为排序驱动模块，重新排序。
2. 阶段间时间点衔接检验：绘制相邻阶段交界处的时间点与排序驱动模块表达值的散点图，确认时间点与模块表达趋势无跳跃性矛盾，确保阶段间时序连贯。

步骤4：最小二乘曲线拟合（必做：正则化与不加正则化对比）

1. 拟合模型选择：分别采用一次、二次、三次多项式进行最小二乘拟合，得到各基因（或模块）的拟合曲线 $\hat{y}(t)$ 。
2. 不加正则化拟合（必做）：通过最小化残差平方和，求解各阶多项式的拟合参数 $a_0, a_1, \dots, a_p$ ，计算拟合后的 R^2 、RMSE，记录拟合效果与曲线形态。
3. 加正则化拟合（必做）：采用 Lasso 正则化最小二乘，调整正则化参数 λ （推荐 $\lambda = 0.01, 0.1, 1.0$ ），分别求解拟合参数，计算对应的 R^2 、RMSE，记录拟合效果与曲线形态。
4. 拟合效果对比（必做）：从 R^2 、RMSE、曲线平滑度三个维度，对比不加正则化与不同 λ 值下正则化拟合的效果，分析正则化对过拟合的抑制作用，明确最优 λ 值选择依据。

5. 其他机器学习类拟合（选做）。采用随机森林回归、支持向量回归（SVR）等方法，对同一基因（或模块）进行拟合，与最小二乘拟合结果对比，分析不同拟合方法的优劣。交叉验证选择最优 λ 。将抽样细胞随机分成 5 折。对每个候选 λ （如 0,0.001,0.01,0.1,0.5,1,2,5,10），重复 5 次：在 4 折上拟合 Lasso 模型，在 1 折上计算 RMSE。记录各 λ 的平均 CV-RMSE，选择最小者作为最优 λ 。绘制 λ -CV 误差曲线，直观呈现 λ 与拟合效果的关系。

步骤 5：误差分析与假设检验

误差分析：计算每个基因（或模块）的 RMSE、 R^2 ，筛选 $R^2>0.5$ 、 $RMSE<0.1$ 的基因（模块）。假设检验：对筛选后的基因进行 Pearson 相关性检验，筛选 $p<0.05$ 的基因，得到显著趋势基因集合 G_s 。时间点充足性验证：计算残差方差 σ^2 ， $\sigma^2<0.05$ 说明时间点充足，否则增加抽样量重新拟合。

步骤 6：细胞轨迹排序与验证（选做）

6.1 基于基因投票的排序

收集显著趋势基因（ $R^2>0.5$, $p<0.05$ ）及其拟合曲线 $\hat{y}_g(t)$ 。对每对抽样细胞 (j_1, j_2) ，若多数基因的拟合值满足 $\hat{y}_g(t_{j_1}) < \hat{y}_g(t_{j_2})$ ，则判定 j_1 应排在 j_2 之前。通过所有细胞对的比较，得到全序（可采用 Kemeny 启发式算法）。输出排序后的细胞列表。

6.2 排序合理性验证（NMI/ARI）

将排序后的细胞按已知各阶段细胞数量划分为相应区间，得到预测阶段标签。计算预测标签与真实标签的 NMI 和 ARI。判断标准：NMI>0.6 且 ARI>0.5 为合理；否则检查显著趋势基因筛选阈值或投票策略。

6.3 从抽样细胞到全体细胞的伪时间扩展

采用最近邻插值：对全体细胞中的每个细胞，计算其与所有抽样细胞在显著趋势基因表达上的欧氏距离，取距离最近的 k 个抽样细胞（ $k=5$ ），以距离倒数为权重加权平均其伪时间，得到全体细胞的伪时间。可选：用随机森林回归模型预测全体细胞伪时间。

步骤 7：轨迹解读（选做）

将显著趋势基因按拟合曲线形态分类（保守型、分支特异型），结合 2.2 节双分支分化过程，基于基因趋势差异，反向解释细胞分化轨迹的分子机制[10]。

步骤 8：负对照实验（选做）

随机打乱时间点对原始分配的时间点向量 t 进行随机打乱 100 次。每次打乱后，重复步骤 4 和步骤 5，计算所有基因的平均 R^2_{shuffle} 和平均 $RMSE_{\text{shuffle}}$ 。比较原始平均 R^2 与 R^2_{shuffle} 分布：若原始 R^2 大于 95%分位数，则认为轨迹有效；否则认为轨迹不可靠。报告打乱前后的 R^2 箱线图。

四、实验中可能出现的问题及解决方法

可能出现的问题	问题原因	解决方法
---------	------	------

基因拟合误差过大 ($R^2 < 0.5$)	1. 时间点分配不合理, 顺序混乱; 2. 抽样量不足; 3. 基因无明显表达趋势	1. 重新对同一阶段细胞排序, 验证排序合理性; 2. 增加抽样量, 满足 $n_s \geq \max(3p + 1, 0.05M)$; 3. 剔除无显著趋势的基因 ($p \geq 0.05$)
K-means 聚类效果差 (轮廓系数 < 0.5)	1. 模块数 k 选择不当; 2. 基因表达矩阵未标准化彻底	1. 调整 k 值, 选取轮廓系数最大的 k; 2. 重新进行标准化处理, 检查标准化公式应用是否正确
细胞轨迹排序与已知标签时序不符	1. 显著趋势基因筛选阈值不当; 2. 双分支排序未锚定起始细胞	1. 调整筛选阈值 (如降低 R^2 至 0.4, 确保基因数量充足); 2. 以共同起始阶段细胞为锚点, 重新整合分支排序结果
拟合出现过拟合 (R^2 极高但验证误差大)	多项式阶数过高, 模型过度拟合噪声	采用正则化最小二乘, 调整 λ 参数; 或降低多项式阶数 (如从三次改为二次)
阶段内排序无明显规律 ($\rho \leq 0.6$)	排序驱动模块选择不当, 未体现细胞发育进度差异	更换排序驱动模块 (重新筛选阶段间差异更显著的模块), 重新排序并验证
正则化拟合效果不佳 (RMSE 无明显下降)	λ 参数选择不当, 正则化强度过强或过弱	调整 λ 参数范围 (如 0.001–10), 绘制 λ -RMSE 曲线, 选取 RMSE 最小时对应的 λ 值; 或采用 5 折交叉验证选择最优 λ
投票排序产生环 (无法得到全序)	显著趋势基因中存在矛盾的表达式	增加排序聚合算法的容错 (如仅考虑多数投票, 放弃平局对); 剔除表达趋势矛盾的基因, 重新筛选显著趋势基因
负对照中打乱后 R^2 仍较高	数据中本身存在随机相关性或多项式过拟合	降低多项式阶数, 增大正则化 λ , 或使用更严格的显著性阈值 (如 $p < 0.01$) 筛选显著趋势基因

交叉验证选择 λ 时过拟合	验证集划分随机性导致	使用重复交叉验证 (5×2 或 10×5) 或嵌套交叉验证, 降低验证集划分随机性的影响
全体细胞排序扩展误差大	抽样细胞代表性不足或显著趋势基因数量少	增加抽样量 (如 $n_s \geq 0.1M$), 或使用高斯过程回归代替最近邻, 提升排序预测精度; 增加显著趋势基因筛选数量

五、参考文献

- [1] Satija R, Farrell JA, Gennert D, et al. Spatial reconstruction of single-cell gene expression data. *Nature Biotechnology*, 2015, 33(5): 495-502. PMID: 25867923. DOI: 10.1038/nbt.3192. (单细胞 RNA-seq 技术打破群体平均化分析; HVG 筛选与表达矩阵标准化标准方法)
- [2] Kester L, van Oudenaarden A. Single-cell transcriptomics meets lineage tracing. *Cell Stem Cell*, 2018, 23(2): 166-179. DOI: 10.1016/j.stem.2018.04.014. (细胞标签对应分化状态, 为时序分析提供基础; HSC 双分支分化路径)
- [3] Patel AP, Tirosh I, Trombetta JJ, et al. Single-cell RNA-seq highlights intratumoral heterogeneity in primary glioblastoma. *Science*, 2014, 344(6190): 1396-1401. DOI: 10.1126/science.1254257. (NSC 双分支分化: 神经元特异基因与胶质细胞特异基因差异; 同一标签细胞异质性验证)
- [4] Trapnell C, Cacchiarelli D, Grimsby J, et al. The dynamics and regulators of cell fate decisions are revealed by pseudotemporal ordering of single cells. *Nature Biotechnology*, 2014, 32(4): 381-386. DOI: 10.1038/nbt.2859. (双分支轨迹解析无需依赖复杂伪时间算法; 单细胞伪时间排序与 Monocle 轨迹推断逻辑; Spearman 相关系数验证排序合理性)
- [5] Box GEP, Draper NR. *Empirical Model-Building and Response Surfaces*. New York: John Wiley & Sons, 1987. ISBN: 978-0471810339. (最小二乘拟合样本量约束公式、残差分析及拟合优度评价)
- [6] Tibshirani R. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 1996, 58(1): 267-288. DOI: 10.1111/j.2517-6161.1996.tb02080.x. (Lasso 正则化最小二乘方法、拟合精度分析及假设检验框架)
- [7] Breiman L. Random forests. *Machine Learning*, 2001, 45(1): 5-32. DOI: 10.1023/A:1010933404324. (选做部分其他机器学习拟合方法——随机森林回归)
- [8] Drucker H, Burges CJC, Kaufman L, et al. Support vector regression machines. In: *Advances in Neural Information Processing Systems 9*, 1997: 155-161. (选做部分其他机器学习拟合方法——支持向量回归 SVR)
- [9] Qiu X, Mao Q, Tang Y, et al. Reversed graph embedding resolves complex single-cell trajectories. *Nature Methods*, 2017, 14(10): 979-982. DOI: 10.1038/nmeth.4402. (Monocle 2 双分支轨迹构建与反图嵌入方法)
- [10] Macosko EZ, Basu A, Satija R, et al. Highly parallel genome-wide expression profiling of individual cells using nanoliter droplets. *Cell*, 2015, 161(5): 1202-1214. DOI: 10.1016/j.cell.2015.05.002. (单细胞表达矩阵预处理与 Drop-seq 维度优化)
- [11] Zinovyev A, Sadovsky M, Calzone L, et al. Modeling progression of single cell populations through the cell cycle as a sequence of switches. *Frontiers in Molecular Biosciences*, 2022, 8: 873441. DOI: 10.3389/fmolb.2022.873441. (单细胞群体时序建模与排序思路)
- [12] Langfelder P, Horvath S. WGCNA: an R package for weighted correlation network analysis. *BMC Bioinformatics*, 2008, 9: 559. DOI: 10.1186/1471-2105-9-559. (K-means 聚类准则 SSE、基因模块中心向量计算; 基因共表达模块聚类与加权网络分析经典方法)